

Pengembangan Sistem Big Data Terintegrasi untuk Analisis Kecelakaan Jalan Raya di Inggris Menggunakan Apache Spark dan SQL-NoSQL

**Leoni Nazwa Friskilla Sibuea^{*1}, Hizkia Abednego Sipayung², Nathanael Tumpak Joy Tampubolon³,
Whisnu Abraham Luciano Saragih⁴, Imel Sari Sinaga⁵**

1,2,3,4,5Program Studi Sarjana Terapan Teknologi Rekayasa Perangkat Lunak, Fakultas Vokasi, Institut Teknologi Del

Email: 1leonisibuea25@gmail.com, 2hizkiabednego@gmail.com, 3nathanaeltampubolonsklh1005@gmail.com,
4whisnu.abraham.l.s@gmail.com, 5iimelsinagaa@gmail.com

*Penulis Korespondensi

(Naskah masuk: dd mmm yyyy, diterima untuk diterbitkan: dd mmm yyyy)

Abstrak

Kecelakaan jalan raya merupakan masalah transportasi yang perlu dianalisis secara berbasis data karena berkaitan dengan keselamatan, jumlah korban, dan mobilitas masyarakat. Penelitian ini mengembangkan sistem Big Data terintegrasi untuk menganalisis pola kecelakaan jalan raya di Inggris menggunakan Road Accidents Dataset dari Kaggle yang terdiri dari 307.973 baris dan 21 kolom. Sistem dibangun dengan Apache Spark untuk ingestion, cleaning, preprocessing, feature engineering, agregasi, analisis tren, dan clustering *hotspot* menggunakan K-Means. PostgreSQL digunakan untuk menyimpan data terstruktur dan hasil agregasi, sedangkan MongoDB digunakan untuk menyimpan data berbasis dokumen dan hasil integrasi. Hasil analisis menunjukkan bahwa kecelakaan didominasi oleh kategori Slight, kendaraan yang paling sering terlibat adalah Car, dan jenis jalan dengan jumlah kecelakaan tertinggi adalah Single carriageway. Dari sisi wilayah, Birmingham menjadi district dengan jumlah kecelakaan tertinggi. Dari sisi waktu, kecelakaan cenderung meningkat pada jam sibuk, terutama pagi dan sore hari, serta lebih banyak terjadi pada weekday dibandingkan weekend. Hasil visualisasi melalui *dashboard* Streamlit dan Plotly membantu pengguna membaca pola kecelakaan berdasarkan tingkat keparahan, waktu, lokasi, jenis kendaraan, jenis jalan, jumlah korban, dan speed limit secara lebih mudah.

Kata kunci: Big Data, Apache Spark, PostgreSQL, MongoDB, analisis kecelakaan, dashboard interaktif

Development of an Integrated Big Data System for Road Traffic Accident Analysis in Great Britain Using Apache Spark and SQL-NoSQL

Abstract

Road traffic accidents are transportation issues that require data-driven analysis because they are related to safety, casualties, and public mobility. This study develops an integrated Big Data system for analyzing road accident patterns in Great Britain using the Road Accidents Dataset from Kaggle, consisting of 307,973 rows and 21 columns. The system uses Apache Spark for ingestion, cleaning, preprocessing, feature engineering, aggregation, trend analysis, and accident hotspot clustering with K-Means. PostgreSQL is used to store structured data and aggregation results, while MongoDB is used to store document-based data and integration results. The analysis shows that most accidents fall into the Slight category, the most frequently involved vehicle type is Car, and the road type with the highest number of accidents is Single carriageway. Birmingham is identified as the district with the highest accident count. From a temporal perspective, accidents tend to increase during peak hours, particularly in the morning and afternoon, and occur more frequently on weekdays than weekends. The Streamlit and Plotly dashboard helps users understand accident patterns based on severity, time, location, vehicle type, road type, casualties, and speed limit more easily.

Keywords: Big Data, Apache Spark, PostgreSQL, MongoDB, accident analysis, interactive dashboard

1. PENDAHULUAN

Kecelakaan jalan raya masih menjadi isu penting dalam keselamatan transportasi karena dapat menimbulkan korban jiwa, kerugian ekonomi, dan gangguan mobilitas masyarakat. World Health Organization mencatat bahwa kematian akibat kecelakaan lalu lintas berada pada angka sekitar 1,19 juta jiwa per tahun (World Health Organization, 2023). Di Great Britain, laporan tahunan terbaru menunjukkan 128.272 korban kecelakaan pada tahun 2024, termasuk 29.467 korban dalam kategori killed or seriously injured (Department For Transport, 2025). Angka tersebut menunjukkan bahwa data kecelakaan perlu dianalisis secara sistematis agar pola kejadian, faktor risiko, dan wilayah rawan dapat dipahami dengan lebih jelas.


Data kecelakaan memiliki karakteristik kompleks karena memuat atribut temporal, spasial, kategorikal, dan numerik. Data tersebut tidak cukup hanya dilihat secara manual, terutama ketika jumlah *record* mencapai ratusan ribu. Proses analisis membutuhkan *pipeline* yang mampu membaca, membersihkan, mengolah, menyimpan, dan memvisualisasikan data secara terstruktur. Apache Spark relevan digunakan karena mendukung pemrosesan data skala besar, menyediakan API untuk beberapa bahasa pemrograman, serta memiliki komponen Spark SQL dan MLlib untuk analisis data dan *machine learning* (Apache Spark, 2026).

Beberapa penelitian sebelumnya menunjukkan bahwa data kecelakaan dapat dianalisis menggunakan pendekatan *machine learning* untuk memahami tingkat keparahan dan faktor yang berkontribusi terhadap kecelakaan (Ahmed *et al.*, 2023). Pendekatan *clustering* juga dapat digunakan untuk mengelompokkan wilayah rawan kecelakaan sehingga hasil analisis lebih mudah digunakan dalam pengambilan keputusan (Herry Wahyono, 2024). Namun, sebagian penelitian masih berfokus pada satu bagian analisis, seperti prediksi tingkat keparahan atau pemetaan *hotspot*. Penelitian ini menekankan integrasi proses dalam satu alur kerja, mulai dari *preprocessing*, analisis, penyimpanan SQL-NoSQL, hingga visualisasi *dashboard*.

Berdasarkan kebutuhan tersebut, penelitian ini menyusun sistem Big Data terintegrasi menggunakan Apache Spark, PostgreSQL, MongoDB, Streamlit, dan Plotly untuk menganalisis data kecelakaan jalan raya di Great Britain. Penelitian ini bertujuan membangun *pipeline* Big Data, menganalisis pola kecelakaan berdasarkan *severity*, waktu, lokasi, jenis jalan, jenis kendaraan, dan speed limit, serta menyajikan hasilnya dalam *dashboard* interaktif. Fokus penelitian berada pada integrasi proses dan analisis deskriptif, bukan pada model prediksi kausal. Hasil penelitian diharapkan menjadi dasar awal untuk memahami pola keselamatan jalan.

2. METODE PENELITIAN

Penelitian ini menggunakan pendekatan *pipeline* Big Data secara end-to-end. Pendekatan ini dipilih karena proses penelitian tidak hanya membaca dataset, tetapi juga mencakup tahap pengambilan data, pembersihan data, *preprocessing*, analisis, penyimpanan, integrasi basis data, dan visualisasi. Pengolahan data dilakukan secara *batch processing* karena dataset diproses dalam satu rangkaian kerja, bukan secara *real-time*. Alur ini digunakan agar data mentah dapat diubah menjadi informasi yang lebih terstruktur dan mudah dianalisis melalui *dashboard*.



Gambar 1. Tahapan Metodologi Penelitian

2.1. Dataset Penelitian

Dataset yang digunakan dalam penelitian ini adalah Road Accidents Dataset dari Kaggle dengan nama file Road Accident Data.csv. Dataset ini berisi data kecelakaan jalan raya di Great Britain dan dapat diakses melalui tautan:

<https://www.kaggle.com/datasets/atharvasoundankar/road-accidents-dataset>

Dataset ini dipilih karena memiliki jumlah data yang besar dan variasi atribut yang sesuai untuk kebutuhan analisis Big Data. Selain itu, dataset ini mendukung proses *preprocessing*, analisis deskriptif, *clustering hotspot*, integrasi database SQL-NoSQL, dan visualisasi *dashboard* interaktif. Dengan karakteristik tersebut, dataset ini relevan digunakan untuk mengembangkan sistem Big Data terintegrasi dalam analisis kecelakaan jalan raya.

2.2. Alur Pipeline Big Data

Alur penelitian disusun dalam bentuk *pipeline* Big Data secara end-to-end. Proses dimulai dari penyimpanan dataset di Google Drive, kemudian data

dimuat ke Google Colab dan diproses menggunakan Apache Spark. Tahapan pengolahan meliputi ingestion, *cleaning*, *preprocessing*, pembuatan fitur baru, analisis deskriptif, dan *clustering hotspot*. Hasil pengolahan kemudian disimpan ke PostgreSQL dan MongoDB, lalu divisualisasikan melalui *dashboard* menggunakan Streamlit dan Plotly.

2.3. Cleaning, Preprocessing dan Analisis Data

Tahap *cleaning* dan *preprocessing* dilakukan agar data siap dianalisis. Proses ini mencakup pengecekan missing value dan duplikasi, perbaikan penulisan kategori, penyesuaian format tanggal dan waktu, serta normalisasi nama kolom. Setelah itu, dibuat fitur tambahan berupa *is_weekend*, *severity_rank*, dan *high_severity_flag* untuk membedakan hari kerja dan akhir pekan, mengubah tingkat keparahan ke bentuk numerik, serta menandai kecelakaan serius dan fatal.

Data yang sudah bersih kemudian dianalisis secara deskriptif menggunakan Apache Spark. Analisis dilakukan berdasarkan tingkat keparahan, waktu kejadian, wilayah, jenis kendaraan, jenis jalan, kondisi cuaca, kondisi permukaan jalan, dan batas kecepatan. Selain itu, penelitian ini menggunakan K-Means dari Spark MLlib untuk mengelompokkan *hotspot* kecelakaan berdasarkan latitude, longitude, speed_limit, number_of_casualties, dan number_of_vehicles. Jumlah cluster ditentukan sebanyak 10 cluster sesuai kebutuhan pemetaan wilayah rawan kecelakaan.

2.4. Integrasi SQL-NoSQL dan Visualisasi Dashboard

Hasil pengolahan data disimpan ke dalam dua jenis basis data, yaitu PostgreSQL dan MongoDB. PostgreSQL digunakan untuk menyimpan data terstruktur dan hasil agregasi dalam bentuk tabel, seperti data kecelakaan bersih, ringkasan tingkat keparahan, tren waktu, ringkasan wilayah, dan ringkasan batas kecepatan. Sementara itu, MongoDB digunakan untuk menyimpan data dalam bentuk dokumen agar lebih fleksibel digunakan pada proses visualisasi.

Integrasi SQL-NoSQL dilakukan dengan mengambil hasil query dari PostgreSQL, kemudian mengubahnya ke format dictionary dan menyimpannya ke MongoDB. Data hasil integrasi tersebut digunakan sebagai sumber *dashboard*. Visualisasi dibuat menggunakan Streamlit dan Plotly untuk menampilkan jumlah kecelakaan, jumlah korban, tingkat keparahan, wilayah dengan kecelakaan tertinggi, tren waktu, *hotspot*, dan ringkasan analisis lainnya.

2.5. Pengujian Sistem

Pengujian sistem dilakukan untuk memastikan seluruh alur *pipeline* berjalan dengan benar. Pengujian mencakup pembacaan dataset, proses

cleaning dan *preprocessing*, analisis menggunakan Apache Spark, penyimpanan data ke PostgreSQL, integrasi data ke MongoDB, serta visualisasi *dashboard* menggunakan Streamlit dan Plotly.

Keberhasilan sistem dilihat dari kemampuan setiap tahap menghasilkan *output* tanpa kesalahan. Data harus berhasil dibaca, dibersihkan, dianalisis, disimpan ke database, dipindahkan dari PostgreSQL ke MongoDB, dan ditampilkan pada *dashboard*. Dengan pengujian ini, sistem dapat dipastikan berjalan sebagai satu alur Big Data yang terintegrasi dari data mentah sampai visualisasi hasil analisis.

3. HASIL DAN PEMBAHASAN

3.1. Implementasi Pipeline Big Data

Sistem Big Data berhasil dibangun melalui beberapa tahap, mulai dari ingestion, *cleaning*, *preprocessing*, analisis, penyimpanan database, integrasi SQL-NoSQL, hingga visualisasi *dashboard*. Dataset diproses menggunakan Apache Spark di Google Colab. Hasil profiling menunjukkan bahwa dataset memiliki 307.973 baris dan 21 kolom. Setelah proses pembersihan, data menjadi lebih konsisten dan siap digunakan untuk analisis.

Data hasil pengolahan kemudian disimpan ke PostgreSQL dan MongoDB. PostgreSQL digunakan untuk menyimpan data terstruktur dan hasil agregasi, sedangkan MongoDB digunakan untuk menyimpan data berbasis dokumen. Alur ini menunjukkan bahwa sistem mampu menghubungkan proses pengolahan, penyimpanan, dan visualisasi dalam satu *pipeline* yang terintegrasi.

3.2. Analisis Tingkat Keparahan Kecelakaan

Hasil analisis menunjukkan bahwa kecelakaan paling banyak berada pada kategori Slight, yaitu 263.280 kejadian. Kategori Serious berada di urutan kedua dengan 40.740 kejadian, sedangkan kategori Fatal memiliki jumlah paling rendah, yaitu 3.953 kejadian. Pola ini menunjukkan bahwa sebagian besar kecelakaan dalam dataset termasuk kecelakaan ringan. Namun, kategori Serious dan Fatal tetap perlu diperhatikan karena berkaitan langsung dengan risiko keselamatan dan dampak korban yang lebih besar.




Gambar 2. Jumlah Kecelakaan Berdasarkan Tingkat Keparahan

3.3. Analisis Jenis Kendaraan

Berdasarkan jenis kendaraan, Car menjadi kendaraan yang paling sering terlibat dalam kecelakaan. Hal ini dapat terjadi karena mobil banyak


digunakan dalam aktivitas harian. Jenis kendaraan lain seperti Van/Goods, Motorcycle, Bus or coach, dan Pedal cycle memiliki jumlah yang lebih kecil dibandingkan mobil. Meskipun demikian, kendaraan seperti sepeda motor tetap perlu diperhatikan karena penggunaanya lebih rentan mengalami cedera saat kecelakaan.



Gambar 3. Jumlah Kecelakaan Berdasarkan Jenis Kendaraan

3.4. Analisis Jenis Jalan

Hasil analisis berdasarkan jenis jalan menunjukkan bahwa Single carriageway memiliki jumlah kecelakaan tertinggi dibandingkan jenis jalan lainnya. Jenis jalan ini umumnya memiliki arus lalu lintas dua arah tanpa pemisah fisik yang kuat. Kondisi tersebut dapat meningkatkan potensi konflik antarkendaraan, terutama saat kendaraan berbelok, menyalip, atau berada pada kondisi lalu lintas padat. Namun, hasil ini tidak langsung berarti single carriageway paling berbahaya, karena jumlah kecelakaan juga dipengaruhi oleh tingkat penggunaan jalan.



Gambar 4. Jumlah Kecelakaan Berdasarkan Jenis Jalan

3.5. Analisis Wilayah Kecelakaan

Hasil analisis wilayah menunjukkan bahwa Birmingham menjadi *district* dengan jumlah kecelakaan tertinggi. Wilayah lain yang juga memiliki jumlah kecelakaan tinggi adalah Leeds, Manchester, Bradford, Westminster, Sheffield, Liverpool, Cornwall, Barnet, dan Bristol City. Pola ini menunjukkan bahwa kecelakaan banyak terjadi pada wilayah dengan aktivitas transportasi dan mobilitas tinggi.


Jumlah kecelakaan yang tinggi pada wilayah perkotaan dapat berkaitan dengan padatnya perjalanan harian, tingginya volume kendaraan, dan beragamnya aktivitas transportasi. Hasil ini dapat digunakan sebagai dasar awal untuk melihat wilayah yang perlu mendapat perhatian lebih dalam analisis keselamatan jalan.



Gambar 5. Top District dengan Kecelakaan Tertinggi


3.6. Analisis Waktu Kecelakaan

Kecelakaan cenderung rendah pada dini hari, kemudian meningkat pada pagi dan sore hari. Peningkatan pada pagi hari berkaitan dengan aktivitas berangkat kerja dan sekolah, sedangkan peningkatan pada sore hari berkaitan dengan aktivitas pulang kerja, pulang sekolah, dan mobilitas harian lainnya.



Gambar 6. Tren Kecelakaan per Jam


Perbandingan *weekday* dan *weekend* juga menunjukkan bahwa kecelakaan lebih banyak terjadi pada *weekday*. Hal ini dapat terjadi karena aktivitas harian, perjalanan rutin, dan distribusi barang lebih banyak berlangsung pada hari kerja. Namun, hasil ini tetap perlu dibaca secara hati-hati karena *weekday* terdiri dari lima hari, sedangkan *weekend* hanya dua hari.



Gambar 7. Perbandingan Weekend dan Weekday

3.7. Clustering Hotspot Kecelakaan

Analisis *hotspot* dilakukan menggunakan algoritma K-Means dari Spark MLlib. Atribut yang digunakan meliputi latitude, longitude, speed_limit, number_of_casualties, dan number_of_vehicles. Jumlah cluster ditentukan sebanyak 10 cluster untuk membantu mengelompokkan wilayah dengan karakteristik kecelakaan yang mirip.



Gambar 8. Heatmap Hotspot Kecelakaan

4. KESIMPULAN

Penelitian ini berhasil mengembangkan sistem Big Data terintegrasi untuk analisis kecelakaan jalan raya di Great Britain menggunakan Apache Spark, PostgreSQL, MongoDB, Streamlit, dan Plotly. Apache Spark digunakan untuk memproses dataset melalui tahap ingestion, *cleaning*, *preprocessing*, analisis deskriptif, dan *clustering hotspot*. PostgreSQL digunakan untuk menyimpan data terstruktur dan hasil agregasi, sedangkan MongoDB digunakan untuk menyimpan data berbasis dokumen dan hasil integrasi SQL-NoSQL.

Hasil analisis menunjukkan bahwa kecelakaan paling banyak berada pada kategori Slight, kendaraan yang paling sering terlibat adalah Car, dan jenis jalan dengan jumlah kecelakaan tertinggi adalah Single carriageway. Dari sisi wilayah, Birmingham menjadi *district* dengan jumlah kecelakaan tertinggi. Dari sisi waktu, kecelakaan cenderung meningkat pada jam sibuk, terutama pagi dan sore hari, serta lebih banyak terjadi pada *weekday* dibandingkan *weekend*.

Dashboard yang dibangun menggunakan Streamlit dan Plotly mampu menyajikan hasil analisis dalam bentuk visual yang lebih mudah dipahami. Sistem ini dapat membantu pengguna melihat pola kecelakaan berdasarkan tingkat keparahan, wilayah, waktu, jenis kendaraan, jenis jalan, *hotspot*, dan *speed limit*. Penelitian ini masih bersifat deskriptif, sehingga pengembangan berikutnya dapat diarahkan pada analisis prediktif, penambahan variabel lalu lintas, serta evaluasi risiko kecelakaan secara lebih mendalam.

5. DAFTAR PUSTAKA

Ahmed, S. *et al.* (2023) 'Transportation Research Interdisciplinary Perspectives A study on road accident prediction and contributing factors using explainable machine learning models : analysis and performance', *Transportation Research Interdisciplinary Perspectives*, 19(April), p. 100814. Available at:

<https://doi.org/10.1016/j.trip.2023.100814>.

Apache Spark (2026) *Overview: Apache Spark Documentation*. Available at: <https://spark.apache.org/docs/latest/>.

Department For Transport (2025) 'Reported Road Casualties Great Britain: Annual Report 2023'. London. Available at: <https://www.gov.uk/government/statistics/reported-road-casualties-great-britain-annual-report-2023>.

Herry Wahyono (2024) 'K-Means Clustering for Identifying Traffic Accident Hotspots in Depok City', *Journal of Applied Research in Computer Science and Information Systems*, 2, pp. 159–170. Available at:

<https://doi.org/10.61098/jarcis.v2i1.182>.

World Health Organization (2023) *Global status*

report on road safety 2023. Geneva: World Health Organization. Available at: <https://www.who.int/publications/i/item/9789240086517>.